

## 腹部超音波画像からの腫瘍検出

B3 原 英吾

### 1 研究背景および目的

#### ● 背景

- 検査実施者は器具の操作と診断を同時に行わなければならない  
高難易度
- 肝臓は沈黙の臓器と呼ばれ初期には自覚症状がほとんどない
  - \* 症状を自覚している時には重症化している場合が多い
- 機械学習による診断のサポート
  - \* 提供されているデータには、図 1 の様に明らかなラベル不足のある画像が存在する




図 1: ラベル不足のある診断画像例


#### ● 目的

- 既存の研究を踏まえたモデルの精度向上
  - \* noisy label<sup>1</sup>による精度低下の改善
- 超音波支援システムの開発
  - \* 早期発見につながると良い


### 2 これまでの研究のまとめ

#### ● データセット


- 国立研究開発法人日本医療研究開発機構 (AMED)<sup>2</sup>が提供している延べ 8 万枚に及ぶ以下のデータが付随
  - \* 腹部超音波画像, ROI
  - \* 年齢, 性別




(a) 性別毎の画像枚数



(b) 診断名毎の年齢分布



(c) 診断名毎の画像サイズの分布



(d) 診断名毎の bbox の割合

図 2: データセットにおけるデータの分布

#### — 性別 (図 2a)

- \* hcc(肝細胞癌) は男性が罹患しやすい
  - ・ 昔は男性の方が飲酒・タバコが多く癌に罹りやすかったという時代背景があるかもしれない
- \* hemangioma(血管腫) は女性が罹患しやすい
- \* meta(転移性肝癌) は他の症状よりも少ない

#### — 年齢 (図 2b)

- \* cyst(単純嚢胞), hemangioma(血管腫) の分布にはあまり特徴がない

<sup>1</sup>今回は図 1 の様なアノテーションが不足しているものを指す

<sup>2</sup><https://www.amed.go.jp/>

- \* hemangioma(血管腫) は比較的若年層でも罹患する
- \* meta(転移性肝癌) における 0 歳はラベルミスである可能性が高い
- \* hcc(肝細胞癌) は比較的高齢者が罹患しやすい
- 画像サイズ (図 2c)
  - \* hemangioma(血管腫) は比較的画像サイズが統一されている
    - ・ 腫瘍の大きさが血管に依存するためあまり偏りが生じていない?
- bbox の画像に占める割合 (図 2d)
  - \* cyst(単純嚢胞) は他の診断と比べて bbox の割合が低い ( $\frac{1}{2}$  程度) である
  - \* hcc(肝細胞癌) は画像に占める bbox の割合が高い
- 症状毎の特徴を調査




図 3: 症状毎における腫瘍の超音波画像

- cyst(単純嚢胞) (図 3a)
  - \* 液体が貯留されている状態
  - \* 症状がでないことが多いため大きな腫瘍になって発見されることが多い
  - \* 嚢胞の内腔に向けて増殖するため転移することは少ない
- hemangioma(血管腫) (図 3b)
  - \* 肝臓にできる良性腫瘍の中で最も多い
  - \* 女性ホルモンが原因で女性が罹患しやすいと言われているが詳しくは解明されていない
  - \* 血管が無数に絡み合うことによって出来た血管の塊であることから血流が遅いという特徴がある
  - \* 他の臓器に浸潤したり転移することは無いと言われている
- meta(転移性肝癌) (図 3c)
  - \* 門脈を介して大腸癌などの消化器癌から転移する割合が多い
  - \* 類似したエコーパターンをもつ腫瘍が多発してみられることが多い
- hcc(肝細胞癌) (図 3d)
  - \* 肝臓にできる悪性腫瘍の中で最も多いと言われている
  - \* 約 90 %がウイルス感染症が原因
    - ・ B 型肝炎ウイルス (HBV) が約 20%
    - ・ C 型肝炎ウイルス (HCV) が約 70%
- データクレンジング
  1. 400 × 400 以下の画像の除外
  2. Perceptual Hash を利用した類似画像の除外
  3. 青色や黄色のスケールの除去
- 提供されているデータを COCODataset の形式に変換
  - train data : test data : val data = 67122 : 8390 : 8391
  - 見やすいようにインデントしたものも作成<sup>3</sup>

<sup>3</sup>[//aka/work/hara.e/AMED/lib/dataset/annotations/train\\_large.json](https://aka/work/hara.e/AMED/lib/dataset/annotations/train_large.json) など

- 1 クラス (腫瘍) での学習

- 実験のパラメーター

|                  |                     |
|------------------|---------------------|
| seed             | 0                   |
| model pretrained | YOLOX-s<br>ImageNet |
| data 数           | 67122               |
| batch_size       | 64                  |
| total_epoch      | 50                  |
| input_size       | (512, 512)          |
| weight_decay     | 0.0005              |
| momentum         | 0.9                 |
| scheduler        | yoloxwarmcos        |
| criterion        | BCELoss             |
| device           | gpgpu8              |
| 計算時間             | 30 min/epoch        |

表 1: 学習に用いた条件






図 4: yoloXwarmcos

- Double Descent[1] が起きている

- \* Noisy Label が最大の要因



(a) AP



(b) loss

図 5: YOLOX で 1 クラスの検出を行った時の AP と loss

表 2: 学習で得られた精度

| model    | backbone       | num_classes | mAP   | IoU              |                  |                 | area <sup>4</sup> |                 |  |
|----------|----------------|-------------|-------|------------------|------------------|-----------------|-------------------|-----------------|--|
|          |                |             |       | AP <sub>50</sub> | AP <sub>75</sub> | AP <sub>S</sub> | AP <sub>M</sub>   | AP <sub>L</sub> |  |
| YOLOX[2] | Decoupled head | 1           | 0.519 | 0.839            | 0.558            | -               | 0.639             | 0.631           |  |

- 実験からわかったこと

- 図 5b から

- \* Noisy Label の影響が大きい
      - ・ IoU の精度が悪い
      - ・ Double Descent が起きている
    - \* クラスの誤分類は少ない
      - ・ 1 クラス分類なので当たり前

<sup>4</sup>Small < 32<sup>2</sup> < Medium < 96<sup>2</sup> < Large

### 3 前回の GM からの進捗

- プログラムを作成し IoU 毎に PR 曲線を描画




図 6: 1 クラス検出における PR 曲線

- 図 6 から Recall が低いことがわかる
  - \* 医療用で Recall が低いのは問題
  - \* Recall が低いということは腫瘍を検出できていないということ
- 目加田先生と研究の今後の方針について話し合った
  - ゴールとしては悪性腫瘍 (見逃し厳禁) と良性腫瘍を見分けること
  - 検出器 (YOLOX[2]) と分類器 (自己教師あり学習) を合わせたモデルを構築して精度を測る
    - \* 分類器について今のところ SimCLR[3] (対照学習) を検討中

### 4 今後の課題&スケジュール

- 5/17 までに
  1. 4 クラスの検出を 300epoch で学習させる
  2. 悪性腫瘍・良性腫瘍の Precision, Recall を算出する
  3. 対照学習のコードを書き始める
- 5/31 までに
  - 対照学習の結果を (遅くとも 6/14 までに) 出すことを目標にする

### 参考文献

- [1] Anonymous authors. **DEEP DOUBLE DESCENT: WHERE BIGGER MODELS AND MORE DATA HURT** ICLR 2020, 2020.
- [2] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, and Jian Sun. **YOLOX: Exceeding YOLO Series in 2021**, 2021.
- [3] Ting Chen, Simon Kornblith, Mohammad Norouzi, Geoffrey Hinton. **A Simple Framework for Contrastive Learning of Visual Representations**, 2020.