

腹部超音波画像からの腫瘍検出

B4 原 英吾

1 研究背景および目的

● 背景

- 器具の操作と診断を同時に行わなければならない高難易度
- 肝臓は沈黙の臓器と呼ばれ初期には自覚症状がほとんどない
 - * 症状を自覚している時には重症化している場合が多い
- 機械学習による診断のサポート
 - * 良性・悪性を見分けることが重要視される
 - * 図 1 の様に明らかなラベル不足¹のある画像が存在する

● 目的

- 既存の研究を踏まえたモデルの精度向上
 - * 良性・悪性判別の高精度化
- 超音波支援システムの開発
 - * 早期発見につながると良い





図 1: ラベル不足のある診断画像例


2 これまでの研究のまとめ

● データセット


- 国立研究開発法人日本医療研究開発機構 (AMED)²が提供している延べ 8 万枚に及ぶ以下のデータが付随
 - * 腹部超音波画像, ROI
 - * 年齢, 性別




(a) 性別毎の画像枚数



(b) 診断名毎の年齢分布



(c) 診断名毎の画像サイズの分布



(d) 診断名毎の bbox の割合

図 2: データセットにおけるデータの分布

— 性別 (図 2a)

- * HCC(肝細胞癌) は男性が罹患しやすい
 - ・ 昔は男性の方が飲酒・タバコが多く癌に罹りやすかったという時代背景があるかもしれない
- * hemangioma(血管腫) は女性が罹患しやすい
- * Meta(転移性肝癌) は他の症状よりも少ない

— 年齢 (図 2b)


- * cyst(単純嚢胞), hemangioma(血管腫) の分布にはあまり特徴がない
- * hemangioma(血管腫) は比較的若年層でも罹患する

¹今回は図 1 の様なアノテーションが不足しているものを指す

²<https://www.amed.go.jp/>

- * Meta(転移性肝癌) における 0 歳はラベルミスである可能性が高い
- * HCC(肝細胞癌) は比較的高齢者が罹患しやすい
- 画像サイズ (図 2c)
 - * hemangioma(血管腫) は比較的画像サイズが統一されている
 - ・ 腫瘍の大きさが血管に依存するためあまり偏りが生じていない?
- bbox の画像に占める割合 (図 2d)
 - * cyst(単純嚢胞) は他の診断と比べて bbox の割合が低い ($\frac{1}{2}$ 程度) である
 - * HCC(肝細胞癌) は画像に占める bbox の割合が高い

● 症状毎の特徴を調査



(a) cyst(単純嚢胞)

(b) hemangioma(血管腫)

(c) Meta(転移性肝癌)

(d) HCC(肝細胞癌)

図 3: 症状毎における腫瘍の超音波画像

- cyst(単純嚢胞) (図 3a)
 - * 液体が貯留されている状態
 - * 症状がでないことが多いため大きな腫瘍になって発見されることが多い
 - * 嚢胞の内腔に向けて増殖するため転移することは少ない
- hemangioma(血管腫) (図 3b)
 - * 肝臓にできる良性腫瘍の中で最も多い
 - * 女性ホルモンが原因で女性が罹患しやすいと言われているが詳しくは解明されていない
 - * 血管が無数に絡み合うことによって出来た血管の塊であることから血流が遅いという特徴がある
 - * 他の臓器に浸潤したり転移することは無いと言われている
- Meta(転移性肝癌) (図 3c)
 - * 門脈を介して大腸癌などの消化器癌から転移する割合が多い
 - * 類似したエコーパターンをもつ腫瘍が多発してみられることが多い
- HCC(肝細胞癌) (図 3d)
 - * 肝臓にできる悪性腫瘍の中で最も多いと言われている
 - * 約 90 %がウイルス感染症が原因
 - ・ B 型肝炎ウイルス (HBV) が約 20%
 - ・ C 型肝炎ウイルス (HCV) が約 70%

● データクレンジング

1. 400 × 400 以下の画像の除外
2. Perceptual Hash を利用した類似画像の除外
3. 青色や黄色のスケールの除去

● 提供されているデータを COCODataset の形式に変換

- train data : test data : val data = 67122 : 8390 : 8391
- 見やすいようにインデントしたファイル³も作成

³[//aka/work/hara.e/AMED/lib/dataset/annotations/train_large.json](https://aka/work/hara.e/AMED/lib/dataset/annotations/train_large.json) など

- 1 クラスと 4 クラス検出の学習結果




図 4: 1 クラス検出と 4 クラス検出の比較

- 図 4a から
 - 4 クラス検出の方が AP が低い
- 図 4b から
 - 1 クラスと 4 クラスは、同じくらいの学習速度で iou_loss の差異が小さい
 - クラス数を増やしても IoU の精度はあまり変化が無い
- 図 4c から
 - 1 クラスと 4 クラスでは cls_loss の差異が大きい

表 1: 1 クラス検出と 4 クラス検出の学習で得られた精度

model	backbone	classes	epoch	size	batch_size	IoU			area		
						mAP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
YOLOX[2]	DarkNet	1	300	512	64	0.519	0.839	0.558	-	0.639	0.631
		4				0.279	0.526	0.248	-	0.221	0.288

- 表 1 から
 - AP が半分程度になっている
 - IoU が 0.5 の時は AP が比較的高い
 - 4 クラス検出では腫瘍が大きいものは分類しやすい傾向がある？

表 2: 4 クラス検出時の評価指標毎の値

Diagnosis	未検出数	データ総数	未検出割合	accuracy	precision	recall	f1-score
cyst	60	3037	0.0198	0.8789	0.9179	0.9539	0.9356
HCC	106	1371	0.0773	0.4758	0.5801	0.7257	0.6448
hemangioma	180	2962	0.0608	0.7238	0.8451	0.8346	0.8398
Meta	71	1021	0.0695	0.1397	0.8258	0.1440	0.2452
合計	417	8391	0.0497	0.7760	-	0.7760	-

- 表 2 から
 - cyst (単純嚢胞)
 - * ほぼ問題ない
 - hemangioma (血管腫)
 - * cyst (単純嚢胞) や HCC (肝細胞癌) と誤分類してしまうことが多い
 - * 未検出の多さが目立つ
 - HCC (肝細胞癌)
 - * hemangioma (血管腫) と誤分類してしまうことが多い
 - * 未検出が多い
 - Meta (転移性肝癌)
 - * HCC (肝細胞癌) や hemangioma (血管腫) と誤分類してしまうことが多い
 - * 正確な予測ができていない (予測がバラバラ) ことが多い

3 前回の GM からの進捗

- YOLOX[2] と SimCLR[3] から CenterNet[4] と SimSiam[5] へモデルの変更

– 背景

- * YOLOX[2] の backbone を finetuning して重みを固定する予定だった
- * 複雑なモデルのためクラスの特徴量を backbone の外でも操作していて finetuning するのは面倒臭い
- * SimCLR[3] はバッチサイズが大きくないと効果的に学習できない

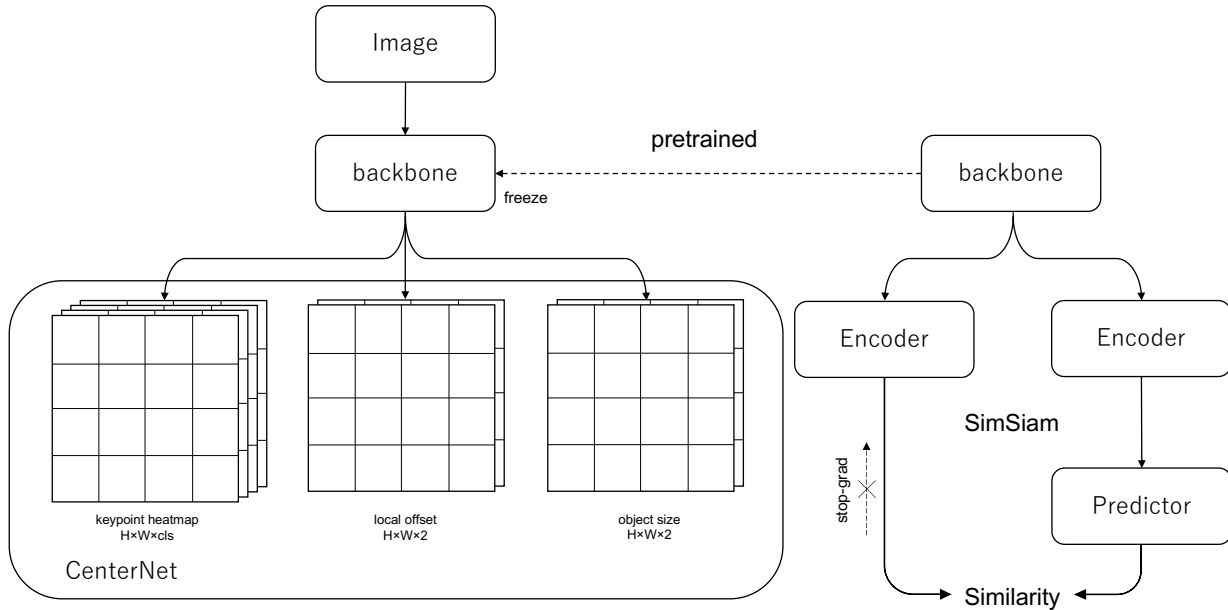


図 5: CenterNet[4] と SimSiam[5] の複合モデル

– 推論フロー

1. SimSiam (距離学習) で backbone を finetuning
2. backbone の重みを freeze
3. backbone から特徴マップを取得し CenterNet[4] のパラメータのみを学習させる

- SimSiam で backbone (ResNet18) を事前学習 (途中)

- 実験で用いる SimSiam[5] のコード⁴を書いた
- 元論文のコードは backbone の fc 層しか用いられていなかった
- (自分の書いたコードじゃないからかもしれないが) 汚くて使いにくかった

- CenterNet[4] で 4 クラス検出の学習

- 実験の簡略化のため初めは MMDetection を用いる
- 実験が進んでいったら自分でコードを書くつもり...

表 3: 1 クラス検出と 4 クラス検出の学習で得られた精度

model	backbone	classes	epoch	size	batch_size	IoU			area		
						mAP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
YOLOX[2]	DarkNet	1	300	512	64	0.519	0.839	0.558	-	0.639	0.631
		4				0.279	0.526	0.248	-	0.221	0.288
CenterNet[4]	ResNet18	4	140	512	16	0.344	0.639	0.332	-	0.347	0.326

- 4 クラスの検出ではいずれ指標でも CenterNet[4] の方が高精度
 - * Recall は同程度だが Precision は 5%~10% 程高い
 - * 中心を推定した後に高さと幅を推定する手法と円形である腫瘍の相性が良かった?
- YOLOX に比べて約 10 倍高速
- Loss や AP, 混同行列などは間に合わなかったので後日載せる

⁴<https://github.com/a5chin/AMED/blob/feature/examples/examples/simsiam.py>

4 今後の課題&スケジュール

- 6/14 までに
 - － 対照学習の結果を (遅くとも 6/28 までに) 出すことを目標にする
 - － 結果と言っても test データで Precision や Recall を出すところまで
 - － YOLOX の 4 クラス検出の結果と比較できる様にする

付録 A CenterNet での検出結果




図 6: 000020.jpg の検出結果




図 7: 000814.jpg の検出結果

参考文献

- [1] Anonymous authors. **DEEP DOUBLE DESCENT: WHERE BIGGER MODELS AND MORE DATA HURT** ICLR 2020, 2020.
- [2] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, and Jian Sun. **YOLOX: Exceeding YOLO Series in 2021**, 2021.
- [3] Ting Chen, Simon Kornblith, Mohammad Norouzi, Geoffrey Hinton. **A Simple Framework for Contrastive Learning of Visual Representations**, 2020.
- [4] Xingyi Zhou, Dequan Wang, Philipp Krähenbühl. **Objects as Points**, 2019.
- [5] Xinlei Chen, Kaiming He. **Exploring Simple Siamese Representation Learning**, 2020.